

Aluna: Janyne Soares da Silva

Atividade Semana 4

1. SELEÇÃO DOS DADOS

1.1 Análise inicial: Examine as colunas disponíveis na base e descreva suas características (tipo, propósito e relevância). o Indique quais variáveis são relevantes para o estudo da evasão e quais podem ser descartadas, justificando suas decisões.

COLUNA	TIPO	PROPÓSITO	RELEVÂNCIA PARA EVASÃO
Idade	NÃO ESTRUTURADO	Identificar a faixa etária do estudante	Alta: perfis etários podem influenciar a permanência no curso
Gênero		Caracterizar o perfil demográfico por sexo	Média: pode revelar padrões de evasão por grupo
Estado Civil		Descrever a situação conjugal do estudante	Média: responsabilidades familiares podem impactar a continuidade
Renda Familiar (R\$)		Mensurar a condição socioeconômica da família	Alta: fator financeiro está diretamente associado à evasão
Escola Ensino Médio		Verificar se a escola é privada ou pública	Média: base de formação pode influenciar o desempenho
Status		Indicar a situação atual da matrícula	Essencial: é a variável-alvo da análise
Motivo da Evasão		Descobrir o motivo pelo qual o aluno evadiu	Baixa: ausente para alunos ativos
Trabalha Atualmente		Identificar o vínculo profissional do	Alta: conciliar trabalho e estudo é fator de

		estudante	risco de evasão
Último Período Cursado		Registrar o avanço acadêmico do estudante	Alta: períodos iniciais concentram maior risco de evasão
Desempenho		medir o rendimento acadêmico do estudante	Alta: baixo desempenho é um dos principais preditores de evasão

VARIÁVEIS ESSENCIAIS:

Status
Idade
Gênero
Estado civil
Renda familiar
Desempenho
Trabalha Atualmente

OBS:Critério escolhido de descarte

Uma variável foi considerada dispensável quando sua remoção não compromete a capacidade de identificar o perfil do estudante evadido, ou seja, a análise ainda chegaria a conclusões consistentes e significativas sem ela.

DESCARTADAS:

Último período cursado:a informação de avanço acadêmico já é capturada indiretamente pelo Desempenho; sua ausência não compromete a identificação do perfil do evadido.

Motivos da evasão:trata-se de uma consequência da evasão, não de uma característica do perfil do estudante. Além disso, possui 102 valores nulos, estando preenchida apenas para quem já evadiu.

Renda Familiar Total: coluna redundante com valores idênticos à Renda Familiar (R\$), sem acrescentar nenhuma informação nova à análise.

1.2 IDENTIFICAÇÃO DAS REDUNDÂNCIAS

Identificação de redundâncias: Observe a presença de colunas redundantes “Renda Familiar Total”, que é redundante em relação à “Renda Familiar (R\$)”. Explique como redundâncias podem afetar a análise e indique qual coluna manter.

R: A coluna "Renda Familiar Total" apresenta valores idênticos à coluna "Renda Familiar (R\$)", caracterizando uma redundância. A presença de colunas duplicadas pode gerar confusão na interpretação dos dados, além de aumentar desnecessariamente o volume da base sem agregar nenhuma informação nova à análise.

A coluna mantida foi Renda Familiar (R\$), pois já é suficiente para representar a condição socioeconômica do estudante com clareza.

1.3 SELEÇÃO FINAL

Liste as variáveis que permanecerão na base após a seleção.

Status
Idade
Gênero
Estado civil
Renda familiar
Desempenho
Trabalha Atualmente

2. PRÉ-PROCESSAMENTO

2.1 Limpeza de dados: Identifique valores ausentes, replicados e inconsistentes. Descreva as ações de correção aplicadas (remoção, substituição, imputação etc.).

IDENTIFICAÇÃO DE VALORES AUSENTES

COLUNA	QTD. NULOS	AÇÃO APLICADA
Escola Ensino Médio	8	imputação pela moda
Trabalha Atualmente	8	imputação pela moda
Desempenho	8	imputação pela mediana
Motivo da Evasão	102	Mantido — ausência esperada para alunos ativos
Renda Familiar (R\$)	8	imputação pela mediana

VALORES AUSENTES IMPUTADOS:

```
analise.py > ...
1 import pandas as pd
2
3 Explain | Profile
4
5 df = pd.read_excel('base_aed_evasao_pre_processamento.xlsx')
6
7 # Imputação
8 df['Renda Familiar (R$)'] = df['Renda Familiar (R$)'].fillna(2471.13)
9 df['Desempenho'] = df['Desempenho'].fillna(72.2)
10 df['Escola Ensino Médio'] = df['Escola Ensino Médio'].fillna('Privada')
11 df['Trabalha Atualmente'] = df['Trabalha Atualmente'].fillna('Sim')
12
13 # Verificar
14 print(df[['Renda Familiar (R$)', 'Desempenho', 'Escola Ensino Médio', 'Trabalha Atualmente']])
```

Valores ausentes: Imputação

Os valores nulos das colunas numéricas (Renda Familiar e Desempenho) foram preenchidos pela **mediana**, pois ela é menos sensível a valores extremos que a média. As colunas categóricas (Escola Ensino Médio e Trabalha atualmente) foram preenchidas pela **moda**, pois representa o valor mais frequente e mais provável para substituir uma informação desconhecida. A coluna Motivo da Evasão foi mantida com nulos, pois sua ausência é esperada.

VALORES REPLICADOS TRATADOS:



quantidades de duplicatas encontradas= 3

```
analise.py > ...
1 import pandas as pd
2
3 Explain | Profile
4
5 df = pd.read_excel('base_aed_evasao_pre_processamento.xlsx')
6
7 # Remover duplicatas
8 df = df.drop_duplicates()
9
10 print("Linhas após remoção:", len(df))
```

As 3 linhas duplicadas foram removidas da base, pois registros idênticos não acrescentam informação e podem distorcer os resultados da análise.

VALORES INCONSISTENTES TRATADOS:

quantidades de inconsistências encontradas: 7



Valores inconsistentes :Substituição

As inconsistências nas colunas Gênero e Estado Civil foram corrigidas por substituição direta, padronizando variações como FEM, feminino e masc para Feminino e Masculino, e Solteir, Casada, Viuvo e Separado para seus respectivos formatos padronizados. A padronização foi necessária pois valores escritos de formas diferentes são tratados como categorias distintas pelo sistema, o que comprometeria qualquer análise por grupo.

2.2 Integração de dados: Caso houvesse outra planilha (por exemplo, histórico de notas ou frequência), indique qual campo poderia ser usado como chave de integração e quais cuidados devem ser adotados.

R: O correto seria que a base possuísse uma coluna de ID do Aluno, que serviria como chave primária para integrar com qualquer outra planilha de forma segura e precisa.

Os cuidados a serem adotados na integração seriam:

- Garantir que a chave escolhida seja única em ambas as planilhas, evitando duplicações após o cruzamento
- Verificar se os formatos são compatíveis entre as bases, como tipo de dado e padronização de texto
- Tratar valores ausentes na chave antes de realizar a integração, pois registros sem chave seriam perdidos
- Verificar se há registros presentes em uma base e ausentes na outra, decidindo se serão mantidos ou descartados

2.3 Redução de dados: Remova colunas redundantes, com muitos valores nulos ou com baixa variação. Justifique as exclusões realizadas.

Renda Familiar Total — removida por ser redundante com Renda Familiar (R\$)

Motivo da Evasão — removida por ter 102 valores nulos

Último Período Cursado — removida por baixa contribuição para identificação do perfil do evadido

2.4 Transformação de dados: Converta variáveis categóricas para numéricas (ex.: Gênero, Trabalha Atualmente).

	Idade	Gênero	Estado Civil	...	Status	Trabalha Atualmente	Desempenho
0	18	0	0	...	0	0	68.5
1	20	0	2	...	1	0	76.4
2	18	1	3	...	0	0	77.8
3	27	1	0	...	1	1	61.9
4	30	1	0	...	0	1	61.6

[5 rows x 8 columns]

Crie novas variáveis derivadas, como: Faixa_Etária (Ex.: Jovem, Adulto, Maduro)

```
[Running] python -u "c:\Users\Janyne2001\Downloads\atividade semana4\analise.py"
  Idade  Gênero  Estado Civil  ...  Status  Trabalha Atualmente  Desempenho
0    18      0           0  ...      0           0           68.5
1    20      0           2  ...      1           0           76.4
2    18      1           3  ...      0           0           77.8
3    27      1           0  ...      1           1           61.9
4    30      1           0  ...      0           1           61.6

[5 rows x 8 columns]
  Idade  Faixa_Etária
0    18      Jovem
1    20      Jovem
2    18      Jovem
3    27      Adulto
4    30      Adulto
5    27      Adulto
6    19      Jovem
7    26      Adulto
8    18      Jovem
9    33      Adulto
```

Renda_Normalizada (escala 0–1)

	Renda Familiar (R\$)	Renda_Normalizada
0	1414.37	0.018472
1	4238.37	0.075523
2	2295.80	0.036279
3	3765.94	0.065979
4	3991.39	0.070533
5	50000.00	1.000000
6	2425.61	0.038901
7	1564.17	0.021498
8	1752.35	0.025300
9	2173.05	0.033799

Padronize valores de texto e trate outliers (ex.: rendas muito altas, desempenho acima de 100).

	Renda Familiar (R\$)	Renda_Normalizada
0	1414.37	0.208172
1	4238.37	0.851105
2	2295.80	0.408845
3	3765.94	0.743548
4	3991.39	0.794876
5	2471.13	0.448762
6	2425.61	0.438399
7	1564.17	0.242277
8	1752.35	0.285119
9	2173.05	0.380899

Max Renda: 4892.37
Max Desempenho: 88.7

Explique sobre como as transformações melhoraram a qualidade do conjunto de dados.

As transformações realizadas melhoraram a qualidade do conjunto de dados de diferentes formas. A conversão de variáveis categóricas para numéricas permitiu que os dados se tornassem processáveis por algoritmos de mineração, que trabalham exclusivamente com valores numéricos. A criação da **Faixa Etária** transformou uma variável numérica contínua em categorias interpretáveis, facilitando a identificação de padrões de evasão por grupo etário. Já a normalização da Renda para a escala 0–1 eliminou a distorção causada pela diferença de magnitude entre os valores, tornando a variável comparável com as demais da base.

Por fim, o tratamento dos outliers de Renda (R\$ 50.000) e Desempenho (150) removeu valores impossíveis ou atípicos que distorciam tanto a normalização quanto qualquer cálculo estatístico sobre essas colunas.

CÓDIGO COMPLETO:

```
import pandas as pd

df = pd.read_excel('base_aed_evasao_pre_processamento.xlsx')

# 1. Remover duplicatas
df = df.drop_duplicates()

# 2. Imputação de valores ausentes
df['Renda Familiar (R$)'] = df['Renda Familiar (R$)'].fillna(2471.13)
df['Desempenho'] = df['Desempenho'].fillna(72.2)
df['Escola Ensino Médio'] = df['Escola Ensino Médio'].fillna('Privada')
df['Trabalha Atualmente'] = df['Trabalha Atualmente'].fillna('Sim')

# 3. Padronizar inconsistências
```



```

df['Gênero'] = df['Gênero'].replace({'feminino': 'Feminino', 'FEM': 'Feminino', 'masc': 'Masculino'})
df['Estado Civil'] = df['Estado Civil'].replace({'Solteir': 'Solteiro(a)', 'Casada': 'Casado(a)', 'Viuvo': 'Viúvo(a)', 'Separado': 'Separado(a)'})

# 4. Remover colunas desnecessárias
df = df.drop(columns=['Renda Familiar Total', 'Motivo da Evasão', 'Último Período Cursado'])

# 5. Tratar outliers
df['Renda Familiar (R$)'] = df['Renda Familiar (R$)'].apply(lambda x: 2471.13 if x > 10000 else x)
df['Desempenho'] = df['Desempenho'].apply(lambda x: 72.2 if x > 100 else x)

# 6. Converter categóricas para numéricas
df['Gênero'] = df['Gênero'].map({'Feminino': 0, 'Masculino': 1, 'Outro': 2})
df['Trabalha Atualmente'] = df['Trabalha Atualmente'].map({'Não': 0, 'Sim': 1})
df['Escola Ensino Médio'] = df['Escola Ensino Médio'].map({'Pública': 0, 'Privada': 1})
df['Status'] = df['Status'].map({'Ativo': 0, 'Evadido': 1, 'Formado': 2})
df['Estado Civil'] = df['Estado Civil'].map({'Solteiro(a)': 0, 'Casado(a)': 1, 'Divorciado(a)': 2, 'Viúvo(a)': 3, 'Separado(a)': 4})

# 7. Criar Faixa Etária
def faixa_etaria(idade):
    if idade <= 24:
        return 'Jovem'
    elif idade <= 34:
        return 'Adulto'
    else:
        return 'Maduro'

df['Faixa Etária'] = df['Idade'].apply(faixa_etaria)

# 8. Criar Renda Normalizada (escala 0-1)
renda_min = df['Renda Familiar (R$)'].min()
renda_max = df['Renda Familiar (R$)'].max()

```

```
df['Renda_Normalizada'] = (df['Renda Familiar (R$)'] - renda_min) /  
(renda_max - renda_min)  
  
print(df[['Renda Familiar (R$)', 'Renda_Normalizada']].head(10))  
print("\nMáx Renda:", df['Renda Familiar (R$)'].max())  
print("Máx Desempenho:", df['Desempenho'].max())
```