

ANÁLISE DE ARTIGO CIENTÍFICO

Avaliação de Modelos de Classificação em Machine Learning

Disciplina: Introdução à Ciência de Dados

Aluna: Janyne Soares da Silva

Artigo analisado: Comparação de Modelos de Machine Learning para Diagnóstico de Doenças Cardiovasculares: um estudo sobre AVC, Arritmia Cardíaca e DAC. Revista FT, v. 27, ed. 128, nov. 2023.

1. Problema Abordado pelo Artigo

O artigo parte do contexto de que as doenças cardiovasculares (DCVs) representam a principal causa de mortalidade global, com estimativa de 17,9 milhões de mortes em 2019, o equivalente a 32% de todas as mortes no mundo (WHO, 2021). Essas doenças englobam condições críticas como arritmia cardíaca, acidente vascular cerebral (AVC) e doença arterial coronariana (DAC).

O problema central investigado é: *qual modelo de machine learning apresenta o melhor desempenho na tarefa de diagnóstico automático de cada uma dessas três DCVs?* A justificativa dos autores é que a escolha do modelo adequado pode melhorar significativamente a rapidez e a confiabilidade do diagnóstico precoce, levando a intervenções médicas mais oportunas, uma vez que diferentes DCVs variam em complexidade clínica, fatores de risco e padrões de manifestação.

2. Modelos de Classificação Utilizados

Conforme a Seção 3.3 do artigo, foram treinados e avaliados cinco modelos de aprendizado supervisionado, com hiperparâmetros otimizados via biblioteca Optuna e divisão de 80% para treino e 20% para teste. Técnicas de balanceamento de classes (oversampling e undersampling) foram aplicadas quando necessário.

Modelo	Tipo	Função no Estudo
Regressão Logística	Linear / Probabilístico	Baseline interpretável; estima probabilidade de pertencimento à classe positiva.
KNN (K-Nearest Neighbors)	Baseado em instâncias	Classifica com base nos k vizinhos mais próximos; sensível à escala dos dados.
Árvore de Decisão	Baseado em regras	Gera regras hierárquicas de divisão; altamente interpretável pelo clínico.
SVM (Support Vector Machine)	Kernel / Margens	Busca o hiperplano de máxima margem de separação; robusto em alta dimensionalidade.
Random Forest	Ensemble (bagging)	Conjunto de árvores com votação majoritária; reduz variância e overfitting.

Tabela 1 – Modelos avaliados no artigo (Seção 3.3).

3. Métricas Reportadas: Acurácia, Precisão e Revocação

Conforme a Seção 3.4 do artigo, baseada em Vujovic (2021), foram utilizadas quatro métricas de avaliação. As tabelas a seguir reproduzem os valores exatos das Tabelas 1, 2 e 3 do artigo. Células em verde indicam o melhor resultado por métrica.

Métrica	Fórmula	O que mede
Acurácia	$(VP+VN) / \text{Total}$	Taxa geral de acertos, proporção de diagnósticos corretos.
Precisão	$VP / (VP+FP)$	Dos casos classificados como positivos, quantos são realmente positivos.
Revocação (Recall)	$VP / (VP+FN)$	Dos casos positivos reais, quantos foram corretamente detectados.
F1-Score	$2 \times (P \times R) / (P+R)$	Média harmônica entre Precisão e Recall.

Tabela 2 – Definição das métricas utilizadas (Seção 3.4).

Tabela 1 do artigo — Arritmia Cardíaca (MIT-BIH, ~16.000 registros):

Métrica	Reg. Logística	KNN	Árv. Decisão	SVM	Random Forest
Acurácia	95%	95%	93%	95%	95%
Precisão	94%	95%	93%	95%	95%
Recall	94%	95%	93%	95%	95%
F1-Score	95%	95%	93%	95%	95%

Tabela 3 – Reprodução da Tabela 1 do artigo. SVM obteve a maior acurácia global (95,62%); Árvore de Decisão foi o único abaixo dos demais (93%).

Tabela 2 do artigo — Acidente Vascular Cerebral (AVC) (Cleveland Heart Disease / UCI):

Métrica	Reg. Logística	KNN	Árv. Decisão	SVM	Random Forest
Acurácia	85%	88%	70%	86%	78%
Precisão	85%	88%	71%	87%	79%
Recall	85%	89%	71%	87%	78%
F1-Score	85%	89%	70%	87%	78%

Tabela 4 – Reprodução da Tabela 2 do artigo. KNN foi o melhor (Acurácia 88%, F1-Score 89%); Árvore de Decisão obteve o pior desempenho (70%).

Tabela 3 do artigo — Doença Arterial Coronariana (DAC) (Framingham Massachusetts CHD):

Métrica	Reg. Logística	KNN	Árv. Decisão	SVM	Random Forest
Acurácia	84%	82%	75%	84%	84%
Precisão	75%	59%	54%	75%	71%
Recall	53%	53%	55%	50%	53%
F1-Score	53%	53%	55%	47%	52%

Tabela 5 – Reprodução da Tabela 3 do artigo. Três modelos empatam em Acurácia de 84%, mas todos apresentam Recall crítico de 50 a 55%.


4. Visualização dos Dados

O artigo utiliza as seguintes formas de visualização na Seção 4 (Resultados e Discussão):

Visualização no Artigo	Descrição
Tabelas 1, 2 e 3	Tabelas de métricas (Acurácia, Precisão, Recall, F1-Score) por modelo e por doença, principal instrumento de comparação quantitativa dos autores.
Figura 1 – Fluxograma	Pipeline de ML adotado: coleta, pré-processamento, balanceamento, treinamento e avaliação. Adaptado de Poorter et al. (2021).
Figura 2 – Curva ROC (Arritmia)	Curvas ROC para os 5 modelos aplicados à Arritmia. Todos apresentam AUC-ROC bem acima de 0,5 (classificador aleatório).
Figura 3 – Curva ROC (AVC)	Curvas ROC para os 5 modelos aplicados ao AVC. Variações na inclinação indicam diferenças na capacidade discriminativa.
Figura 4 – Curva ROC (DAC)	Curvas ROC para os 5 modelos aplicados à DAC. Desempenho inferior comparado às outras doenças, porém todos acima de AUC=0,5.


Tabela 6 – Visualizações presentes no artigo (Seção 4).

Figura 1 – Métricas por modelo: Arritmia Cardíaca




SVM lidera com acurácia de 95,62%. Todos os modelos apresentam desempenho elevado e homogêneo.

Figura 2 – Métricas por modelo: AVC



KNN lidera (Acurácia 88%, Recall 89%). Árvore de Decisão tem pior desempenho (70%).

Figura 3 – Métricas por modelo: DAC



Queda crítica no Recall em todos os modelos (50 a 55%), evidenciando dificuldade estrutural com o dataset de DAC.

5. Opinião Crítica sobre os Resultados

5.1 Os resultados foram satisfatórios?

Para a Arritmia Cardíaca, os resultados são muito satisfatórios. Todos os modelos atingiram acurácia entre 93% e 95%, com precisão e recall igualmente altos. Os autores atribuem isso ao maior volume de dados do MIT-BIH (~16.000 registros). O SVM foi o destaque com 95,62% de acurácia, conforme indicado na Seção 4 e na Conclusão do artigo.

Para o AVC, os resultados são bons e clinicamente relevantes: KNN obteve 88% de acurácia e 89% de F1-Score, seguido pelo SVM (86 a 87%). A Árvore de Decisão (70%) ficou claramente abaixo dos demais.

Para a DAC, os resultados são insatisfatórios do ponto de vista clínico. Embora três modelos atinjam 84% de acurácia, o recall cai para 50 a 55%, o que significa que metade dos casos reais de DAC não seria identificada, algo inaceitável na prática médica. Os próprios autores reconhecem que os datasets Cleveland e Framingham têm menor volume de registros do que o MIT-BIH, prejudicando o aprendizado.

5.2 Há equilíbrio entre Precisão e Revocação?

Critério	Reg. Log.	KNN	Árv. Dec.	SVM	Rand. Forest
Equilíbrio P/R – Arritmia	✓ Sim	✓ Sim	✓ Sim	✓ Sim	✓ Sim
Equilíbrio P/R – AVC	✓ Sim	✓ Sim	✓ Sim	✓ Sim	✓ Sim
Equilíbrio P/R – DAC	✗ Não	≈ Parcial	✓ Sim	✗ Não	✗ Não
Acurácia ≥ 85% (Arritmia)	✓ Sim	✓ Sim	✗ Não	✓ Sim	✓ Sim
Acurácia ≥ 85% (AVC)	✓ Sim	✓ Sim	✗ Não	✓ Sim	✗ Não
Acurácia ≥ 80% (DAC)	✓ Sim	✓ Sim	✗ Não	✓ Sim	✓ Sim

Tabela 7 – Análise de equilíbrio Precisão/Recall com base nos dados originais do artigo.

Para Arritmia e AVC, todos os modelos apresentam equilíbrio praticamente perfeito entre precisão e recall, com diferença máxima de 1 a 2 pontos percentuais. Para a DAC, o desequilíbrio é grave: o SVM tem Precisão de 75% e Recall de apenas 50% (diferença de 25 pp); a Regressão Logística chega a 22 pp de diferença (75% × 53%). Somente a Árvore de Decisão equilibra os valores na DAC (54% × 55%), porém com desempenho global inferior.

5.3 O modelo atende ao problema proposto?

Conforme concluem os próprios autores na Seção 5, não existe um único modelo superior em todas as situações, sendo o melhor modelo dependente da doença analisada:

Doença	Melhor Modelo	Avaliação
Arritmia Cardíaca	SVM	Melhor performance geral (95,62% de acurácia). Todos os modelos atendem bem, com diferença pequena entre eles.
AVC	KNN	Maior acurácia (88%) e F1-Score (89%). Atende bem ao problema de triagem clínica.
DAC	Reg. Log. / SVM / RF (empate em acurácia)	Nenhum modelo atende adequadamente: Recall de 50 a 55% é clinicamente inaceitável para triagem. Recomenda-se ampliar o dataset e aplicar técnicas como SMOTE.

Tabela 8 – Síntese das conclusões do artigo por doença.

O estudo é bem conduzido metodologicamente, com uso de pipeline padronizado, otimização de hiperparâmetros com Optuna e curvas ROC como avaliação complementar. O principal mérito é demonstrar que a acurácia isolada pode ser enganosa: os modelos para DAC têm 84% de acurácia, mas Recall de apenas 50%, tornando-os inadequados para triagem clínica real.